A pergunta do trabalho: Características Associadas aos Sinistros de Trânsito nos Horários de Pico

Grupo APPA

Outubro de 2026

Fatec Baixada Santista – Rubens Lara | Tecnologia em Ciência de Dados | Teoria do Aprendizado Estatístico

Prof. Dr. João Paulo Ferreira de Mello | Repositório:
`https://github.com/kyl8/aprendizado-estatistico`

Integrantes: Arthur Galvão
Pedro Henrique
Ailana

1 Introdução

Os sinistros de trânsito são um problema frequente nas cidades, principalmente nos horários de pico, quando há maior circulação de veículos e pessoas. O aumento do fluxo pode favorecer congestionamentos, frenagens e conflitos no trânsito. Este trabalho apresenta o banco de dados escolhido, formula a pergunta sobre a maior ocorrência de sinistros nos horários de pico e verifica se os dados permitem respondê-la. Para isso, serão analisados os registros de sinistros, considerando seus horários e outras características disponíveis no banco de dados. A análise busca identificar padrões e possíveis fatores relacionados à maior frequência de ocorrências nesses períodos. Assim, a pergunta central é: **que características registradas dos sinistros de trânsito estão associadas à sua ocorrência nos horários de pico?** A base descreve apenas sinistros que aconteceram, sem o volume de tráfego em circulação; por isso a análise identifica associações e não permite concluir causas.

Em segurança viária e mobilidade urbana, compreender os mecanismos subjacentes a essa concentração temporal é imprescindível para órgãos de planejamento de tráfego,

secretarias municipais e operadoras de rodovias. A literatura de tráfego aponta que o aumento de sinistros nesses períodos decorre da combinação entre saturação da malha viária, redução do intervalo de seguimento (*headway*) entre veículos, atrito entre modais heterogêneos (veículos pesados, motocicletas e pedestres) e pressões temporais dos deslocamentos pendulares. Sob o arcabouço de Teoria do Aprendizado Estatístico (JAMES et al., 2021), o estudo adota uma abordagem inferencial fundamentada em modelos supervisionados de classificação, estimando a associação entre as características viárias e operacionais dos sinistros e a ocorrência no pico, sem interpretá-la como efeito causal.

2 O banco de dados e o problema

O conjunto de dados foi extraído do repositório oficial do Infosiga SP (INFOSIGA-SP, 2026), gerido pelo Departamento Estadual de Trânsito de São Paulo (Detran-SP), abrangendo as ocorrências registradas entre janeiro de 2025 e junho de 2026. A base consolida dados de boletins policiais e notificações viárias em todo o território estadual. Conforme preconiza a norma técnica da Associação Brasileira de Normas Técnicas para pesquisa viária (ASSOCIAçãO BRASILEIRA DE NORMAS TéCNICAS, 2020), adota-se rigorosamente a denominação "sinistro de trânsito", superando o termo coloquial "acidente".

Cada linha da base representa uma ocorrência única de sinistro de trânsito devidamente registrada por boletim de ocorrência policial. Foram selecionados os boletins com horário de ocorrência válido e tipo de via informado, totalizando $n = 151175$ observações e $p = 11$ preditores candidatos. As variáveis contemplam atributos de infraestrutura (`tipo_via`), características do evento (`tp_sinistro_primario`), temporalidade (`dia_da_semana`), gravidade (`fatal`) e a contagem discriminada de modais envolvidos (`qtd_automovel`, `qtd_motocicleta`, `qtd_onibus`, `qtd_caminhao`, `qtd_pedestre`, `qtd_bicicleta` e total de `veiculos`).

A escolha deste banco fundamenta-se na alta completude cadastral dos boletins policiais e na relevância concreta do problema: gestores de mobilidade e comandos de policiamento viário necessitam de evidências quantitativas para priorizar intervenções de engenharia de tráfego, temporização semafórica dinâmica e patrulhamento preventivo nos corredores de maior atrito.

3 A pergunta

A pergunta norteadora da pesquisa é enunciada de forma direta: **que características registradas dos sinistros de trânsito estão associadas à sua ocorrência nos horários de pico?** A Tabela 1 sintetiza os sete campos metodológicos que estruturam formalmente a investigação.

Tabela 1 – Ficha da pergunta

Campo	**Preenchimento**
1. A pergunta, em uma frase	Que características dos sinistros estão associadas à ocorrência nos horários de pico?
2. Resposta Y: coluna, tipo	`pico` — qualitativa (binária: Pico vs. Fora do Pico)
3. Preditores X: quais e quantos	Vias, tipo de colisão, modais envolvidos, dia da semana e gravidade ($p = 11$); `turno` e `hora_sinistro` excluídos
4. Tipo: decisões de modelagem	Supervisionado; classificação; abordagem inferencial (associações)
5. Métrica de avaliação	acurácia e AUC
6. Linha de base a bater	acurácia = 0,598 (chutar a classe mais comum)
7. Dono do problema	Órgãos de trânsito e prefeituras (alocação de efetivo e intervenções semafóricas)

Fonte: Elaborada pelos autores.

A decisão por um problema de **classificação supervisionada com finalidade inferencial** é metodologicamente determinante. Conforme discutido por Bruce e Bruce (2019), em ciências aplicadas o objetivo não é meramente prever se um sinistro pertencerá ao pico, mas identificar e mensurar as razões de chance (*odds ratios*) associadas a cada característica. Modelos lineares generalizados (regressão logística com validação cruzada) permitem descrever essas associações. Como não há dado de fluxo de veículos, elas não medem risco por veículo nem efeito causal; servem para descrever o perfil dos sinistros registrados no pico.

4 Defesa da pergunta

A Tabela 2 consolida o diagnóstico empírico realizado sobre o banco de dados.

Tabela 2 – Diagnóstico do banco

Verificação	**Resultado**
Tamanho ($n \times p$)	151175×11 observações e preditores
Linha de base	acurácia = 0,598 (chutar a classe mais comum)
Maior correlação com Y	não se aplica (resposta qualitativa)
Balanço das classes	`Fora do Pico`: 90451 | `Pico`: 60724
Valores faltantes	nenhum

Fonte: Elaborada pelos autores.

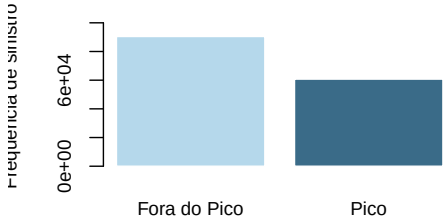
Vazamento. A resposta é definida pela hora do sinistro; por isso `hora_sinistro` e também `turno`, que é derivado dela e separa a resposta (nenhum sinistro da madrugada pertence ao pico), foram retirados dos preditores X. Variáveis como `fatal`, `tp_sinistro_primario` e as contagens de modais são registradas após o evento: servem à descrição do perfil dos sinistros, não à previsão antes de ele ocorrer.

Tamanho ($n \times p$). O conjunto reúne $n = 151175$ observações para $p = 11$ preditores candidatos. Há muito mais observações do que coeficientes (as variáveis categóricas geram

dezenas de termos), o que reduz o risco de sobreajuste (*overfitting*) sem eliminá-lo nem corrigir vieses de registro; a validação cruzada avalia esse risco.

Balanço de classes e faltantes. A resposta binária tem desbalanceamento moderado: 40,2% das ocorrências estão nas faixas de pico (60724 sinistros em 6,5 horas do dia), enquanto 59,8% distribuem-se nas 17,5 horas restantes (90451 sinistros). A classe majoritária já acerta cerca de 59,8% dos casos, e é essa a linha de base a superar. A Figura 1 ilustra essa distribuição. O subconjunto de boletins selecionados não apresenta valores faltantes (`NA`) nas variáveis incluídas; nas contagens de modais, o campo em branco da fonte foi interpretado como zero.

Figura 1 – Distribuição da variável de resposta `pico`



Fonte: Elaborada pelos autores.

Veredito. A pergunta, formulada como associação, é respondível com o banco: há volume e completude suficientes. Ela não permite afirmar causas nem comparar risco entre horários, pois falta o volume de tráfego. Em testes preliminares, um modelo logístico com apenas via, dia da semana e região discriminou pouco (AUC próxima de 0,57) e acertou tanto quanto a classe majoritária; portanto, espera-se associações modestas. As próximas etapas aplicam regressão logística, regularização e validação cruzada, e avaliam uma pergunta alternativa de contagem de sinistros por hora com exposição de calendário.

Referências

ASSOCIAçãO BRASILEIRA DE NORMAS TéCNICAS. *NBR 10697: Pesquisa de sinistros de trânsito — Terminologia*. Rio de Janeiro, 2020.

BRUCE, P.; BRUCE, A. *Estatística Prática para Cientistas de Dados*. [S.l.]: Alta Books, 2019.

INFOSIGA-SP. *Sistema de Informações Gerenciais de Acidentes de Trânsito do Estado de São Paulo*. 2026. Disponível em: <https://www.infosiga.sp.gov.br/>.

JAMES, G. et al. *An Introduction to Statistical Learning: with Applications in R*. 2. ed. [S.l.]: Springer, 2021.