

A pergunta do trabalho: Fatores Associados à Concentração de Sinistros de Trânsito nos Horários de Pico

Grupo APPA

2 de outubro de 2026

Fatec Baixada Santista – Rubens Lara | Tecnologia em Ciência de Dados | Teoria do
Aprendizado Estatístico

Prof. Dr. João Paulo Ferreira de Mello | Repositório:
<https://github.com/kyl8/aprendizado-estatistico>

Integrantes: Arthur Galvão

Pedro Henrique

Ailana

1 Introdução

Os sinistros de trânsito são um problema frequente nas cidades, principalmente nos horários de pico, quando há maior circulação de veículos e pessoas. O aumento do fluxo pode favorecer congestionamentos, frenagens e conflitos no trânsito. Este trabalho apresenta o banco de dados escolhido, formula a pergunta sobre a maior ocorrência de sinistros nos horários de pico e verifica se os dados permitem respondê-la. Para isso, serão analisados os registros de sinistros, considerando seus horários e outras características disponíveis no banco de dados. A análise busca identificar padrões e possíveis fatores relacionados à maior frequência de ocorrências nesses períodos. Assim, a pergunta central é: **por que os sinistros de trânsito acontecem com mais frequência nos horários de pico?**

Em segurança viária e mobilidade urbana, compreender os mecanismos subjacentes a essa concentração temporal é imprescindível para órgãos de planejamento de tráfego, secretarias municipais e operadoras de rodovias. A literatura de tráfego aponta que o

aumento de sinistros nesses períodos decorre da combinação entre saturação da malha viária, redução do intervalo de seguimento (*headway*) entre veículos, atrito entre modais heterogêneos (veículos pesados, motocicletas e pedestres) e pressões temporais dos deslocamentos pendulares. Sob o arcabouço de Teoria do Aprendizado Estatístico (JAMES et al., 2021), o estudo adota uma abordagem inferencial fundamentada em modelos supervisionados de classificação, quantificando o efeito marginal dos fatores operacionais e viários que caracterizam os episódios ocorridos no pico em relação aos demais turnos.

2 O banco de dados e o problema

O conjunto de dados foi extraído do repositório oficial do Infosiga SP (INFOSIGA-SP, 2026), gerido pelo Departamento Estadual de Trânsito de São Paulo (Detran-SP), abrangendo as ocorrências registradas entre janeiro de 2025 e junho de 2026. A base consolida dados de boletins policiais e notificações viárias em todo o território estadual. Conforme preconiza a norma técnica da Associação Brasileira de Normas Técnicas para pesquisa viária (ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS, 2020), adota-se rigorosamente a denominação “sinistro de trânsito”, superando o termo coloquial “acidente”.

Cada linha da base representa uma ocorrência única de sinistro de trânsito devidamente registrada por boletim de ocorrência policial. Foram selecionados os boletins com horário de ocorrência válido, totalizando $n = 151591$ observações e $p = 12$ preditores candidatos. As variáveis contemplam atributos de infraestrutura (`tipo_via`), características do evento (`tp_sinistro_primario`), temporalidade (`dia_da_semana`, `turno`), gravidade (`fatal`) e a contagem discriminada de modais envolvidos (`qtd_automovel`, `qtd_motocicleta`, `qtd_onibus`, `qtd_caminhao`, `qtd_pedestre`, `qtd_bicicleta` e `total_de_veiculos`).

A escolha deste banco fundamenta-se na alta completude cadastral dos boletins policiais e na relevância concreta do problema: gestores de mobilidade e comandos de policiamento viário necessitam de evidências quantitativas para priorizar intervenções de engenharia de tráfego, temporização semaforica dinâmica e patrulhamento preventivo nos corredores de maior atrito.

3 A pergunta

A pergunta norteadora da pesquisa é enunciada de forma direta: **por que os sinistros de trânsito acontecem com mais frequência nos horários de pico?** A Tabela 1 sintetiza os sete campos metodológicos que estruturam formalmente a investigação.

A decisão por um problema de **classificação supervisionada com finalidade inferencial** é metodologicamente determinante. Conforme discutido por Bruce e Bruce (2019),

Tabela 1 – Ficha da pergunta

Campo	Preenchimento
1. A pergunta, em uma frase	Por que os sinistros de trânsito acontecem com mais frequência nos horários de pico?
2. Resposta Y : coluna, tipo	pico — qualitativa (binária: Pico vs. Fora do Pico)
3. Preditores X : quais e quantos	Vias, tipo de colisão, modais envolvidos, dia da semana e severidade ($p = 12$)
4. Tipo: decisões de modelagem	Supervisionado; classificação; abordagem inferencial
5. Métrica de avaliação	acurácia e AUC
6. Linha de base a bater	acurácia = 0,599 (chutar a classe mais comum)
7. Dono do problema	Órgãos de trânsito e prefeituras (alocação de efetivo e intervenções semaforicas)

Fonte: Elaborada pelos autores.

em ciências aplicadas o objetivo não é meramente prever se um sinistro futuro pertencerá ao pico, mas identificar e mensurar as razões de chance (*odds ratios*) de cada fator de risco. Modelos lineares generalizados (regressão logística com inferência assintótica e reamostragem via validação cruzada) permitem isolar o impacto marginal de conflitos entre motocicletas e automóveis em vias arteriais, fornecendo suporte acionável para políticas públicas de redução de sinistralidade.

4 Defesa da pergunta

A Tabela 2 consolida o diagnóstico empírico realizado sobre o banco de dados.

Tabela 2 – Diagnóstico do banco

Verificação	Resultado
Tamanho ($n \times p$)	151591×12 observações e preditores
Linha de base	acurácia = 0,599 (chutar a classe mais comum)
Maior correlação com Y	não se aplica (resposta qualitativa)
Balanço das classes	Fora do Pico: 90743 Pico: 60848
Valores faltantes	nenhum

Fonte: Elaborada pelos autores.


Vazamento. Para evitar contaminação do modelo, as variáveis que definiam a hora original de registro (`hora_sinistro`) foram completamente desconsideradas do conjunto de preditores X . Dessa forma, a classificação opera estritamente sobre características ambientais, viárias e estruturais do sinistro, garantindo que o modelo capture a assinatura comportamental do tráfego no pico sem vazamento de informação trivial.

Tamanho ($n \times p$). O conjunto reúne $n = 151591$ observações para $p = 12$ preditores candidatos. A relação de mais de 12.000 observações por parâmetro assegura ampla estabilidade aos estimadores de máxima verossimilhança, eliminando riscos de sobreajuste

(*overfitting*) e permitindo a inclusão de termos de interação entre tipos de via e modais vulneráveis.

Balanco de classes e faltantes. A resposta qualitativa binária exibe excelente balanço entre as classes: 40,1% das ocorrências concentram-se nas faixas de pico pendular (NA sinistros em apenas 6,5 horas do dia), enquanto 59,9% distribuem-se nas 17,5 horas restantes (NA sinistros). A Figura 1 ilustra essa distribuição. Adicionalmente, o subconjunto de boletins selecionados não apresenta valores faltantes (NA) nas variáveis incluídas na modelagem.

Figura 1 – Distribuição da variável de resposta **pico**



Fonte: Elaborada pelos autores.

Veredito. A pergunta se sustenta plenamente nos dados: o banco possui volume massivo, integridade cadastral e atributos suficientes para explicar a dinâmica dos sinistros no horário de pico por meio de aprendizado estatístico inferencial. A modelagem detalhada será aprofundada nas próximas etapas do projeto através de regressão logística, seleção de preditores por regularização e reamostragem via validação cruzada e bootstrap.

Referências

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. *NBR 10697: Pesquisa de sinistros de trânsito — Terminologia*. Rio de Janeiro, 2020.

BRUCE, P.; BRUCE, A. *Estatística Prática para Cientistas de Dados*. [S.l.]: Alta Books, 2019.

INFOSIGA-SP. *Sistema de Informações Gerenciais de Acidentes de Trânsito do Estado de São Paulo*. 2026. Disponível em: <<http://www.infosiga.sp.gov.br/>>.

JAMES, G. et al. *An Introduction to Statistical Learning: with Applications in R*. 2. ed. [S.l.]: Springer, 2021.