

Aula 6 — Avaliação e seleção de modelos

Erro de treino e de teste; treino/validação/teste; viés–variância; métricas e seleção

Prof. Dr. João Paulo Ferreira de Mello

3 de setembro de 2026

Ciências de Dados

Fatec Rubens Lara – Baixada Santista

O que vamos ver hoje

- **De onde viemos:** já sabemos *ajustar* modelos — `lm()` (Aula 4) e `glm()` (Aula 5).
- **O novo:** como saber se um modelo é *bom* — e, entre vários candidatos, *qual escolher*? A resposta honesta exige medir o erro **fora da amostra**.
- **Para onde vai:** o protocolo treino/validação/teste e o compromisso viés-variância sustentam *todas* as escolhas de modelo do resto do curso (e do seu trabalho).

O fio da aula: uma imobiliária quer prever o **preço** de um imóvel pelo **tamanho** — e tem três modelos candidatos na mesa.

Antes de começar

Primeiro, os dados (a Aula 2 manda: olhe antes de modelar)

São $n = 120$ imóveis — simulados para esta aula — com duas variáveis:

```
head(dados, 4)
```

```
#>      area preco  
#> 1 189.73 443.0  
#> 2 161.31 412.6  
#> 3  78.03 248.2  
#> 4 107.14 305.3
```

Variável	Descrição	Tipo	Unidade
area	área construída	quantitativa contínua	m ²
preco	preço de venda	quantitativa contínua	mil R\$

Preditor $X = \text{area}$; resposta $Y = \text{preco}$ — quantitativa $\Rightarrow$ problema de *regressão* (Aula 1). É sobre esta tabela que toda conta da aula acontece.


O problema: três candidatos, qual escolher?

Com os mesmos 120 imóveis, ajustamos três polinômios:

- **grau 1** (reta): simples demais?
- **grau 3**: curva suave;
- **grau 12**: persegue cada ponto.

Os três “explicam” os dados — em graus diferentes.
Qual você entregaria para a imobiliária usar amanhã?

```
par(mar = c(4,4,1,1), pty = "s")
plot(area, preco, pch = 19, col = "blue",
      xlab = "area (m2)", ylab = "preco (mil R$)")
g <- seq(50, 250, length = 200)
for (k in 1:3)
  lines(g, predict(lm(preco ~ poly(area, c(1,3,12))[k])),
        data.frame(area = g)),
        col = c("green", "orange", "purple")[k], lwd = 2)
```



O que é o “grau”? Os candidatos são polinômios

Os três candidatos são **polinômios** em *area* — o *grau* é o maior expoente usado:

$$\text{grau 1: } \hat{y} = \hat{\beta}_0 + \hat{\beta}_1 \text{ area}$$

$$\text{grau 3: } \hat{y} = \hat{\beta}_0 + \hat{\beta}_1 \text{ area} + \hat{\beta}_2 \text{ area}^2 + \hat{\beta}_3 \text{ area}^3$$

$$\text{grau 12: } \hat{y} = \hat{\beta}_0 + \hat{\beta}_1 \text{ area} + \dots + \hat{\beta}_{12} \text{ area}^{12}$$

Em palavras: cada termo novo dá ao modelo mais liberdade para fazer curvas. O grau é o **botão de flexibilidade** desta aula: grau 1 só desenha retas; grau 12 desenha quase qualquer coisa.

Observação

E continua sendo a regressão da Aula 4: “linear” é *nos* β . O `poly(area, g)` apenas cria as colunas `area`, `area2`, ... — fabricar preditores assim é a *expansão*, tema da Aula 8.

Como se faz uma regressão polinomial: a matemática

O modelo de grau g escreve-se como uma soma de potências:

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \cdots + \beta_g x_i^g + \varepsilon_i.$$

Em forma matricial, $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$, onde $\mathbf{X}$ é a **matriz de desenho**: uma linha por imóvel, uma coluna por potência.

$$\mathbf{X} = \begin{bmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^g \\ 1 & x_2 & x_2^2 & \cdots & x_2^g \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^g \end{bmatrix} \quad \text{ex. } (g = 2), \text{ imóvel 1: } \begin{bmatrix} 1 & 189,73 & 35\,997,5 \end{bmatrix}$$

Em palavras: não inventamos um método novo — *fabricamos colunas* e entregamos ao mesmo estimador de mínimos quadrados da Aula 4: $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$.

No R: três jeitos de escrever o mesmo modelo

```
m1 <- lm(preco ~ area + I(area^2) + I(area^3)) # explicito
m2 <- lm(preco ~ poly(area, 3, raw = TRUE))    # idem, mais curto
m3 <- lm(preco ~ poly(area, 3))                # ortogonal (padrao)
max(abs(fitted(m1) - fitted(m3)))              # mesmas previsoes?

#> [1] 8.527e-13
```

- `I(area^2)`: o `I()` **protege** o `^` — sem ele, a fórmula do R leria `^` como “interações”, não potência.
- A diferença entre os ajustes é $\approx 10^{-13}$ (erro de máquina): é *o mesmo modelo*, escrito de três formas.

Cru ou ortogonal? Mesmo ajuste, coeficientes diferentes

```
signif(coef(m1), 3)  # cru: potencias literais de area
```

```
#> (Intercept)      area  I(area^2)  I(area^3)
#>   1.31e+02   1.48e+00   3.75e-03  -1.50e-05
```

```
signif(coef(m3), 3)  # ortogonal: outra base para o mesmo espaco
```

```
#> (Intercept) poly(area, 3)1 poly(area, 3)2 poly(area, 3)3
#>      366.0      965.0      -94.3      -24.7
```

- **Cru** (`raw = TRUE`): dá a *equação literal*, mas area , area^2 , area^3 são fortemente correlacionadas — contas instáveis em grau alto.
- **Ortogonal** (padrão do `poly`): troca a base por colunas não correlacionadas. *Previsões idênticas*, contas estáveis — é o que usaremos nesta aula.

Cuidado: em grau alto, não interprete cada $\hat{\beta}_j$ isoladamente e **não extrapole** fora da faixa de area — é o que faz a curva de grau 12 mergulhar na borda do gráfico.

Errar dentro e errar fora da amostra

A pergunta certa: errar *onde*?

Definição

O **erro de treino** é medido nos *mesmos* dados usados para ajustar o modelo. O **erro de teste** é medido em dados *novos*, que o modelo nunca viu — é ele que mede a **generalização**.

Em palavras (a analogia da prova): o erro de treino é a nota do aluno refazendo a *lista de exercícios que ele estudou com o gabarito*; o erro de teste é a nota na *prova inédita*. Só a segunda mostra se ele *aprendeu*.

Observação

Quem decora a lista tira 10 nela e vai mal na prova. Modelo que “decora” os dados de treino faz o mesmo — e isso tem nome: **sobreajuste** (Aula 1).

Vendo isso em números

Separamos 70% dos imóveis para *treinar* e 30% para *testar*, e medimos o MSE (erro quadrático médio) dos três candidatos nos dois conjuntos:

```
itr <- sample(120, 84) # 70% para treino
tr <- dados[itr, ]; te <- dados[-itr, ]
mse <- function(m, d) mean((d$preco - predict(m, d))^2)
for (g in c(1, 3, 12)) {
  m <- lm(preco ~ poly(area, g), data = tr)
  cat("grau", format(g, width = 2),
      "| MSE treino:", format(round(mse(m, tr)), width = 5),
      "| MSE teste:", round(mse(m, te)), "\n")
}
```

```
#> grau 1 | MSE treino: 942 | MSE teste: 910
#> grau 3 | MSE treino: 861 | MSE teste: 841
#> grau 12 | MSE treino: 758 | MSE teste: 995
```

Leia a tabela: do grau 1 ao 12, o erro de *treino* só cai (flexibilidade “compra” ajuste). O erro de *teste* cai do grau 1 ao 3 — e volta a **subir** no grau 12. O grau 12 decorou a lista.

Treino, validação e teste

O protocolo básico: separar antes de tudo

treino ($\approx 70\%$)

teste ($\approx 30\%$)

- **Treino:** onde o modelo é *ajustado* (o `lm/glm` roda aqui).
- **Teste:** fica *trancado* até o fim; é usado **uma única vez**, para reportar o desempenho honesto.
- A divisão é **aleatória** (`sample()`), para os dois conjuntos serem parecidos.

Observação

Regra de ouro: o modelo *nunca* pode ver o teste — nem de relance — antes da avaliação final.

E quando há *escolha* de modelo? Três conjuntos

Para *escolher* entre candidatos (grau 1, 3 ou 12?) sem contaminar o teste, entra um conjunto intermediário:



- **treino:** ajusta cada candidato;
- **validação:** compara os candidatos e *escolhe* um — é o *simulado*;
- **teste:** avalia *só o escolhido*, uma vez — é a *prova final*.

Em números: com 300 imóveis, algo como 180/60/60.

Observação

Se você usar o teste para escolher, ele vira validação — e você fica sem nota honesta para reportar.

Viés e variância

Por que o U acontece: duas fontes de erro

Voltando aos três candidatos da imobiliária:

- **Viés** (modelo rígido demais): a **reta** erra *sistematicamente* — não tem como acompanhar a curvatura dos preços, por mais dados que veja.
- **Variância** (modelo flexível demais): o **grau 12** muda de forma se trocarmos meia dúzia de imóveis da amostra — ele segue o *ruído*, não o padrão.

Em palavras: viés é errar sempre do mesmo jeito; variância é acertar “sem firmeza”, mudando de opinião a cada amostra. Flexibilidade *troca* viés por variância.

A decomposição do erro esperado

Para um ponto x_0 , o erro esperado de teste se separa em três parcelas:

$$\mathbb{E}[(y_0 - \hat{f}(x_0))^2] = \underbrace{\text{Var}(\hat{f}(x_0))}_{\text{variância}} + \underbrace{[\text{Bias}(\hat{f}(x_0))]^2}_{\text{viés}^2} + \underbrace{\text{Var}(\varepsilon)}_{\text{irreduzível (Aula 1)}}.$$

Exemplo

$\text{Var}(\hat{f}) = 0,04$, $\text{Bias}(\hat{f}) = 0,3$ e $\text{Var}(\varepsilon) = 0,02$:

$$\text{erro esperado} = 0,04 + (0,3)^2 + 0,02 = 0,04 + 0,09 + 0,02 = 0,15.$$

Aqui o vilão é o *viés* (0,09): vale *aumentar* a flexibilidade.

Observação

$\text{Var}(\varepsilon)$ é o teto da Aula 1: nenhum modelo desce abaixo dele.


A curva em U, agora completa

Variando o grau de 1 a 12 e medindo o MSE nos dois conjuntos:

- **treino**: só desce (mais flexibilidade, mais ajuste);
- **teste**: desce (viés caindo) e volta a subir (variância dominando) — o **U**.

O melhor candidato mora no *fundo do U* — nem rígido, nem decorador.

```
graus <- 1:12; etr <- ete <- numeric(12)
for (g in graus) {
  m <- lm(preco ~ poly(area, g), data = tr)
  etr[g] <- mse(m, tr); ete[g] <- mse(m, te)
}
par(mar = c(4,4,1,1), pty = "s")
matplot(graus, cbind(etr, ete), type = "l",
        lwd = 3, lty = 1, col = c(cverde, claranja),
        xlab = "grau (flexibilidade)", ylab = "MSE")
points(which.min(ete), min(ete), pch = 19,
       cex = 1.4, col = croxo)
```



Métricas e seleção

Qual número olhar? Depende do problema

Problema	Métrica	Leitura
Regressão	MSE	média dos erros ao quadrado
	$RMSE = \sqrt{MSE}$	erro típico, <i>na unidade de Y</i>
	MAE	erro absoluto médio (robusto a outliers)
Classificação	acurácia, precisão, recall	Aula 5
	AUC	desempenho em todos os limiares

Exemplo

No nosso caso, MSE de teste ≈ 900 dá $RMSE \approx 30$: o modelo erra o preço, tipicamente, em **30 mil reais**. É esse número que a imobiliária entende.

Selecionando o modelo, do início ao fim

O procedimento completo, com os três conjuntos:

1. **Ajuste** cada candidato no **treino**;
2. **Compare** todos na **validação** e escolha o melhor;
3. **Reporte** o desempenho do escolhido no **teste** (uma vez).

Exemplo

MSE na *validação*: grau 1 = 2 900; grau 3 = 1 050; grau 12 = 2 300. Escolhe-se o **grau 3**; só então mede-se o teste (digamos, 980) — e é esse o número reportado.

Observação

Repare que a validação “gastou-se” na escolha: por isso o número final vem do teste, que ninguém tocou.

O erro capital: vazamento de dados

Definição

Vazamento (*data leakage*) é qualquer informação do teste — ou do futuro — escorrendo para o ajuste ou para a escolha do modelo.

Três flagrantes clássicos:

- usar o **teste** para escolher o grau/limiar (“testei os 12 e reportei o melhor”);
- **normalizar/imputar** usando a base inteira *antes* de dividir (o treino “vê” médias do teste);
- duplicatas ou o *mesmo cliente* caindo no treino e no teste.

Observação

Sintoma típico no trabalho: desempenho ótimo no papel, decepção em produção. Se está bom *demais*, procure o vazamento.

Exercícios e trabalho

Exercício

Valores reais $y = (10, 12, 15)$ e previsões $\hat{y} = (11, 11, 16)$. Calcule o **MSE** e o **RMSE**.

Exercício

Num ponto, $\text{Var}(\hat{f}) = 0,05$, $\text{Bias}(\hat{f}) = 0,2$ e $\text{Var}(\varepsilon) = 0,03$. Calcule o erro esperado e diga quem domina: viés ou variância? O que você faria com a flexibilidade?

Exercício

Um modelo tem MSE de teste = 2 500 (preço em mil R\$). Qual o RMSE, e como você explicaria esse número para a imobiliária em uma frase?

Exercício (Treino x teste)

Com a analogia da prova, explique por que o erro de treino é quase sempre *menor* que o de teste — e por que essa diferença *cresce* com a flexibilidade.

Exercício (Validação)

Por que escolher o modelo usando o *teste* deixa o desempenho reportado “bom demais”? Que conjunto deveria ter feito esse papel?

Exercício (Caça ao vazamento)

Um colega imputou os faltantes com a média *da base inteira* e depois dividiu treino/teste. Onde está o vazamento, e como corrigir a ordem?

Laboratório — no seu banco de dados

Aplique o protocolo ao seu banco, com dois modelos das aulas passadas:

```
# 1) dividir 70/30 ANTES de qualquer ajuste:
set.seed(1)
itr <- sample(nrow(dados), round(0.7 * nrow(dados)))
tr  <- dados[itr, ]; te <- dados[-itr, ]

# 2) ajustar DOIS candidatos so no treino (ex.: lm simples x multiplo):
m1 <- lm(y ~ x1, data = tr)
m2 <- lm(y ~ x1 + x2, data = tr)

# 3) comparar no TESTE (RMSE = raiz do MSE, na unidade do seu y):
mse <- function(m, d) mean((d$y - predict(m, d))^2)
sqrt(c(m1 = mse(m1, te), m2 = mse(m2, te)))
```

Observação

Entregar: a divisão usada, os dois candidatos, a métrica de teste de cada um, qual você escolheu e *uma frase* traduzindo o RMSE (ou a acurácia) para o dono do problema.

- **Erro de teste** (dados novos) mede generalização; o de treino lisonjeia — é a lista com gabarito.
- **Protocolo:** treino ajusta, **validação** escolhe, **teste** reporta (uma vez).
- **Viés–variância:** flexibilidade troca um pelo outro; o erro de teste faz um **U**.
- **Métrica** na língua do problema (RMSE na unidade de Y); cuidado com **vazamento**.

Próxima aula: e quando os dados são *poucos* para dividir em três? Reaproveitamos: *reamostragem* (validação cruzada e bootstrap).

O protocolo num quadro

	treino	validação	teste
Quem usa	o ajuste (lm/glm)	a comparação	o relatório final
Quantas vezes	muitas	muitas	uma
Analogia	estudar a lista	simulado	prova final
Se mal usado	—	escolha viciada	nota “boa demais”

Observação

Guarde este quadro: ele volta em *toda* aula de modelo daqui em diante.