

Aula 7 — Métodos de reamostragem

Aula 6 — Avaliação e seleção de modelos

Validação cruzada em k dobras; bootstrap; erro padrão e intervalo

Prof. Dr. João Paulo Ferreira de Mello

11 de setembro de 2026

Ciências de Dados

Fatec Rubens Lara – Baixada Santista

O que vamos ver hoje

- **De onde viemos:** a Aula 6 deu o protocolo treino/validação/teste — e ele exige *dados de sobra* para dividir em três.
- **O novo:** e quando não há? **Reamostragem:** em vez de dividir uma vez, dividimos *muitas* — e reaproveitamos cada observação. Daí saem os dois instrumentos da aula: a *validação cruzada*, que escolhe o modelo, e o *bootstrap*, que mede a incerteza dos números dele.
- **Para onde vai:** a validação cruzada é o instrumento que escolhe o *nível de penalização* na Aula 8, a poda das árvores na Aula 11 e os hiperparâmetros de todo o resto do curso.

O fio da aula: a mesma imobiliária — mas agora com a base que ela *realmente* tem, $n = 40$ imóveis.

Por que reamostrar

Os dados de hoje: a mesma imobiliária, com menos sorte

São $n = 40$ imóveis — não 120. Mesmas duas variáveis da Aula 6:

```
dim(dados); head(dados, 3)
```

```
#> [1] 40  2  
#>      area preco  
#> 1 189.73 437.4  
#> 2 161.31 402.6  
#> 3  78.03 212.4
```


Variável	Descrição	Tipo	Unidade
area	área construída	quantitativa contínua	m ²
preco	preço de venda	quantitativa contínua	mil R\$

Uma divisão 70/30 deixaria **12 imóveis** no teste. Doze. Guarde esse número — é dele que nasce o problema da aula.

O problema: uma divisão só é uma loteria

Fixamos o modelo (**grau 3**, o vencedor da Aula 6) e repetimos só o sorteio da divisão 70/30, 200 vezes:

```
ete <- replicate(200, {  
  i <- sample(n, 28) # 28 treino, 12 teste  
  m <- lm(preco ~ poly(area, 3),  
    data = dados[i, ])  
  mse(m, dados[-i, ]) # MSE de teste  
})  
par(mar = c(4,4,1,1), pty = "s")  
hist(ete, breaks = 20, col = cfill, border = "white",  
  main = "", xlab = "MSE de teste",  
  ylab = "frequencia")  
abline(v = mean(ete), col = croxo, lwd = 3)
```



Leia a figura: mesmo banco, mesmo modelo — só o sorteio muda, e o erro varia muito.

Duas queixas contra a divisão única

- **A estimativa é instável.** Com 12 imóveis no teste, dois ou três imóveis atípicos mudam a média. O número que você reporta tem *variância alta*.
- **Os dados são desperdiçados.** O modelo final foi ajustado com 70% das observações; os outros 30% nunca ensinaram nada a ele. Com $n = 40$, jogar fora 12 observações é caro — e um modelo treinado com menos dados é *pior*, então o erro medido é **pessimista**.

Definição


Reamostragem é reutilizar repetidamente subconjuntos dos *mesmos* dados — ajustando o modelo várias vezes — para estimar a incerteza de uma estimativa ou o desempenho de um método.

Em palavras: em vez de perguntar “qual foi o erro nesta divisão?”, perguntamos “qual é o erro *típico*, na média de muitas divisões?”.

Validação cruzada em k dobras

A ideia: todo mundo é teste, uma vez

Embaralhe as n observações e reparta em k blocos de tamanho igual — as **dobras** (*folds*). Faça k rodadas: em cada uma, *uma* dobra é validação e as outras $k - 1$ são treino.



Em palavras: cada observação é usada para *treinar* em $k - 1$ rodadas e para *avaliar* em exatamente uma. Nada se desperdiça, e o erro final é uma *média* de k medidas — por isso muito mais estável que uma só.

O algoritmo, em pseudocódigo

```
entrada: dados com n observacoes, um metodo M, um numero k
1. embaralhe as observacoes e reparta em k dobras D(1), ..., D(k)
2. para j = 1 ate k:
    2.1 ajuste M em todas as dobras EXCETO D(j)
    2.2 E(j) <- erro do modelo ajustado medido em D(j)
3. devolva CV = media de E(1), ..., E(k)
```

Formalmente, com MSE_j o erro na dobra j :

$$CV_{(k)} = \frac{1}{k} \sum_{j=1}^k MSE_j, \quad MSE_j = \frac{1}{|D_j|} \sum_{i \in D_j} (y_i - \hat{f}^{(-j)}(x_i))^2.$$

O expoente $(-j)$ é o essencial: $\hat{f}^{(-j)}$ foi ajustado **sem** a dobra j . Toda predição usada na conta é feita sobre dados que aquele ajuste nunca viu.

No R: as k dobras na mão

```
k      <- 5
dobra  <- sample(rep(1:k, length = n))  # rotulo 1..5 para cada imovel
erro   <- numeric(k)
for (j in 1:k) {
  m     <- lm(preco ~ poly(area, 3), data = dados[dobra != j, ])
  erro[j] <- mse(m, dados[dobra == j, ])
}
round(erro)          # os 5 MSE, uma dobra de cada vez

#> [1] 932 752 936 755 592

mean(erro)           # CV(5)

#> [1] 793.4
```

`rep(1:k, length = n)` gera $1, 2, 3, 4, 5, 1, 2, \dots$ até completar n ; o `sample()` embaralha esses rótulos — é isso, e só isso, que sorteia as dobras. As dobras individuais ainda oscilam; a *média* delas é o número que vamos usar.

Escolhendo o grau por validação cruzada

Empacotando o laço da página anterior numa função de *um* argumento — o grau — a escolha do modelo vira uma linha:


```
cv <- function(g, k = 5) {                                # CV(k) do polinomio de grau g
  d <- sample(rep(1:k, length = n))
  mean(sapply(1:k, function(j)
    mse(lm(preco ~ poly(area, g), data = dados[d != j, ]),
        dados[d == j, ])))
}
graus <- 1:6
round(setNames(sapply(graus, cv), paste0("grau ", graus)))

#> grau 1 grau 2 grau 3 grau 4 grau 5 grau 6
#>    983    877    848    935   1001   1135
```

Leia a saída: o grau 1 (a reta) erra muito — é o *viés*. Sobe-se de flexibilidade, o erro cai, encontra o fundo e volta a subir: é o **U** da Aula 6, agora medido sem depender de um sorteio único.

Por que confiar nessa curva e não em uma divisão

```
avulsa <- function(g) {           # UMA divisao 70/30
  i <- sample(n, 28)
  mse(lm(preco ~ poly(area, g),
        data = dados[i, ], dados[-i, ]))
}
M <- replicate(6, sapply(graus, avulsa))
cv5 <- sapply(graus, cv)
par(mar = c(4,4,1,1), pty = "s")
matplot(graus, M, type = "l", lty = 1, lwd = 1,
        col = "gray70", log = "y",
        xlab = "grau (flexibilidade)",
        ylab = "MSE de validacao")
lines(graus, cv5, col = "roxo", lwd = 4)
```



cinza: 6 divisões avulsas — roxo: $CV_{(5)}$.

Leia a figura: as cinzas discordam — cada uma elegeria um grau; a roxa aponta um vencedor só.

Que k escolher? O compromisso

A própria estimativa $CV_{(k)}$ tem viés e variância — e k regula os dois:

	k pequeno (2, 3)	k grande (20, 30)
Tamanho do treino	50–67% dos dados	quase tudo
Viés da estimativa	maior (pessimista)	pequeno
Variância	menor	maior
Custo	k ajustes	k ajustes (muitos)

- k **pequeno** treina com pouco: modelo pior que o final, erro medido *pessimista* — é viés para cima.
- k **grande** treina com quase tudo, mas os k modelos ficam *quase idênticos* — erros correlacionados, e média de coisas correlacionadas não reduz variância. E as dobras ficam minúsculas.

Observação

Na prática: $k = 5$ **ou** $k = 10$ é o padrão da área — bom equilíbrio entre viés, variância e custo. É o que usaremos no resto do curso.

A validação cruzada também vaza (e é fácil errar)

A Aula 6 avisou sobre **vazamento**. Ele reaparece aqui, disfarçado:

- **Pré-processar antes de dobrar.** Normalizar, imputar faltantes ou selecionar preditores *na base inteira* e só depois cruzar: cada dobra de validação já influenciou o treino. Tudo isso entra **dentro** do laço.
- **Dados agrupados.** Se o mesmo cliente (ou o mesmo imóvel reanunciado) aparece em várias linhas, as dobras precisam separar *grupos*, não linhas.
- **Séries temporais.** Não se sorteia o tempo: treina-se no passado e valida-se no futuro.

Observação

E o teste continua existindo: a validação cruzada substitui o conjunto de *validação*, não o de *teste*. Com dados suficientes, separe um teste final e cruze só o restante.

Bootstrap

Outra pergunta: quanta incerteza tem a minha estimativa?

A validação cruzada responde “*qual método erra menos?*”. O **bootstrap** responde outra coisa:

o meu $\hat{\beta}_1 = 1,71$ mudaria muito se eu tivesse coletado outros 40 imóveis?

Se pudéssemos, a resposta seria trivial: colher 1000 amostras novas da população, calcular $\hat{\beta}_1$ em cada uma, olhar o espalhamento. Mas temos **uma** amostra — as outras 999 não existem.

Definição

O **bootstrap** substitui a população, que não temos, pela *amostra*, que temos: sorteia-se dela, **com reposição**, B novas amostras de tamanho n , e recalcula-se a estatística em cada uma.

Em palavras: a amostra é a melhor fotografia disponível da população. Reamostrá-la imita o ato de coletar dados de novo — *puxar-se pelos próprios cadarços*, que é o que *bootstrap* quer dizer.

O algoritmo do bootstrap

entrada: dados com n observacoes, uma estatística T , um número B

1. para $b = 1$ até B :
 - 1.1 sorteie n observacoes COM REPOSICAO dos dados originais
 - 1.2 $T(b) \leftarrow$ calcule a estatística nessa reamostra
2. erro padrao $\leftarrow$ desvio padrao de $T(1), \dots, T(B)$
3. intervalo $\leftarrow$ percentis 2,5% e 97,5% de $T(1), \dots, T(B)$

Dois detalhes que *fazem* o método:

- **com reposição** — sem ela, sortear n de n devolveria sempre a mesma amostra embaralhada, e T nunca mudaria;
- **tamanho n** — a reamostra imita uma coleta do *mesmo* tamanho, para medir a incerteza que você de fato tem.


Observação

T pode ser qualquer coisa: um coeficiente, uma mediana, um AUC, a diferença entre dois modelos. O bootstrap não pede fórmula — só que você saiba calcular T .

No R: o bootstrap do coeficiente angular

Quanto o preço sobe por m²? Reamostramos $B = 2000$ vezes:

```
B <- 2000
b1 <- replicate(B, {
  i <- sample(n, n, replace = TRUE) # COM reposicao
  coef(lm(preco ~ area, data = dados[i, ]))[2]
})
par(mar = c(4,4,1,1), pty = "s")
hist(b1, breaks = 30, col = cfill, border = "white",
     main = "", xlab = "beta1 reamostrado",
     ylab = "frequencia")
abline(v = quantile(b1, c(.025, .975)),
      col = claranja, lwd = 2, lty = 2)
abline(v = coef(lm(preco ~ area))[2],
      col = croxo, lwd = 3)
```



beta1 reamostrado

roxo: estimativa original — laranja: percentis 2,5% e 97,5%.

Leia a figura: o histograma é a *distribuição amostral* de $\hat{\beta}_1$ — sua largura é a incerteza da estimativa.

Do histograma saem o erro padrão e o intervalo

```
sd(b1)                                # erro padrao bootstrap

#> [1] 0.09993

quantile(b1, c(0.025, 0.975))         # intervalo percentil 95%

#> 2.5% 97.5%
#> 1.525 1.929

summary(lm(preco ~ area))$coef[2, 1:2] # a formula classica, p/ comparar

#> Estimate Std. Error
#> 1.7129      0.0943
```

- O **erro padrão** é o desvio padrão das B estimativas: nenhuma derivação, nenhuma hipótese de normalidade.
- O **intervalo percentil** é o miolo de 95% do histograma.

Repare: bootstrap e fórmula clássica concordam — e o bootstrap segue valendo onde não há fórmula.

Exercícios e trabalho

Exercício

Uma validação cruzada com $k = 5$ deu $MSE_j = (940, 1120, 860, 1310, 1020)$. Calcule $CV_{(5)}$ e o RMSE correspondente, e traduza o RMSE para o dono do problema (preço em mil R\$).

Exercício

Dois candidatos, avaliados nas *mesmas* 5 dobras. Candidato A: (1210, 980, 1150, 1040, 1120). Candidato B: (1020, 1310, 760, 1440, 890). Calcule $CV_{(5)}$ de cada um, diga qual vence — e olhe também a *dispersão* das dobras: o que ela sugere?

Exercício

Um bootstrap com $B = 1000$ deu $\hat{\theta} = 2,4$, desvio padrão das réplicas 0,3 e percentis 2,5% e 97,5% iguais a 1,85 e 3,02. Escreva o erro padrão e o intervalo, e diga se $\theta = 0$ é plausível.

Exercícios — conceituais

Exercício (Por que reamostrar)

Explique, com a figura do início da aula, por que reportar o erro de *uma* divisão 70/30 com $n = 40$ é arriscado. Que duas queixas a reamostragem resolve?

Exercício (O tamanho de k)

Por que um k *pequeno* tende a *superestimar* o erro do modelo final? E por que aumentar k indefinidamente não é a solução?

Exercício (Onde entra a padronização)

Um colega padronizou todos os preditores da base e depois rodou uma CV de 10 dobras. Onde está o vazamento, e qual é a ordem correta das operações?

Exercício (CV ou bootstrap?)

Para cada pergunta, diga qual método usar e por quê: (a) grau 3 ou grau 5? (b) o $\hat{\beta}_1$ é distinguível de zero? (c) qual a incerteza da *mediana* da renda dos clientes? (d) vale a pena trocar um modelo de 10 preditores por um de 3?

Laboratório — no seu banco de dados

Troque a divisão única da Aula 6 por validação cruzada, e qualifique um coeficiente por bootstrap:

```
# 1) CV de 5 dobras comparando DOIS candidatos seus:
k <- 5; d <- sample(rep(1:k, length = nrow(dados)))
cv <- function(formula) mean(sapply(1:k, function(j) {
  m <- lm(formula, data = dados[d != j, ])
  mean((dados$y[d == j] - predict(m, dados[d == j, ]))^2)
}))
c(m1 = cv(y ~ x1), m2 = cv(y ~ x1 + x2))      # menor CV vence

# 2) bootstrap do coeficiente que mais te interessa:
b <- replicate(2000, {
  i <- sample(nrow(dados), nrow(dados), replace = TRUE)
  coef(lm(y ~ x1 + x2, data = dados[i, ]))["x1"]
})
c(ep = sd(b), quantile(b, c(0.025, 0.975)))
```

Entregar em consolidados/: o $CV_{(5)}$ de cada candidato, qual venceu, e uma frase dizendo se o coeficiente escolhido é distinguível de zero — com o intervalo como prova.

- **Reamostrar** é reusar os mesmos dados muitas vezes: uma divisão só é loteria.
- $CV_{(k)}$: k dobras, cada observação valida uma vez; $k = 5$ ou 10 na prática.
- **Vazamento**: todo pré-processamento entra *dentro* do laço das dobras.
- **Bootstrap** (com reposição, tamanho n) dá erro padrão e intervalo sem fórmula alguma.

Próxima aula: a validação cruzada já sabe *medir* o excesso de flexibilidade. Falta um *freio* para ele: expansão de atributos e **regularização** (Ridge, Lasso).